Multihorizontale Windvorhersage mit Gradient Boosting und Conformal Prediction

Filip Bertram
Angewandte Informatik / Hochschule Flensburg

03.2026

Zusammenfassung

Ziel dieser Arbeit ist die Verbesserung kurzfristiger Windvorhersagen durch den Einsatz von Maschinellem Lernen. Hierfür wurde ein multihorizontales Vorhersagesystem entwickelt, das neben Messwerten, meteorologische Prognosen mehrerer numerischer Wettermodelle als Eingabedaten nutzt und für Vorhersagehorizonte von einer bis zwölf Stunden separate Modelle trainiert. Als Regressionsverfahren wurde XGBoost verwendet, da es sich besonders für strukturierte tabellarische Daten eignet und nichtlineare Zusammenhänge zwischen meteorologischen Variablen effizient modellieren kann. Neben der Vorhersage der mittleren Windgeschwindigkeit und maximaler Windböen wurde auch die Windrichtung modelliert. Zur Bewertung kam wurden zeit basierte Walk-Forward Validierung sowie ein separater Holdout Zeitraum verwendet. Zusätzlich wurde Conformal Prediction eingesetzt um Vorhersageintervalle und damit eine Unsicherheitsabschätzung der Prognosen zu erzeugen. Die Ergebnisse zeigen, dass der entwickelte Ansatz stabile und Präzise Vorhersagen über die betrachteten Horizonte ermöglicht und sich für die statistische Nachbearbeitung numerischer Wettermodelle eignet.

1 Einleitung

Die Vorhersage von Wind stellt eine komplexe Herausforderung dar. Wind ist ein hochdynamisches und turbulentes System, das von zahlreichen Meteorologischen Faktoren beeinflusst wird. Kleine Änderungen in atmosphärischen Bedingungen können zu erheblichen Veränderungen der Windgeschwindigkeit führen. Besonders schwierig sind kurzfristige Vorhersagen über wenige Stunden hinweg, da lokale Effekte, Turbulenzen und Geländeeinflüsse eine große Rolle spielen [8].

Traditionell basieren Windvorhersagen auf numerischen Wettervorhersagemodellen (Numerical Weather Prediction, NWP). Diese Modelle simulieren physikalische Prozesse der Atmosphäre, indem sie komplexe Differentialgleichungen lösen[1], die beispielsweise Strömungsdynamik, Energieflüsse und Feuchtetransport beschreiben. Bekannte Beispiele für solche Modelle sind das Global Forecast System (GFS) sowie das integrated Forecast System (IFS). Trotz ihrer Physikalischen Genauigkeit weisen diese Modelle häufig systematische Fehler auf, insbesondere bei lokalen Vorhersagen und in komplexen Gelände [8].

In den letzten Jahren hat sich daher der Einsatz von Maschinellem Lernen zur Verbesserung dieser meteorologischer Vorhersagen etabliert[4, 8]. Maschinelles Lernen kann hierbei genutzt werden, um systematische Fehler numerischer Wettermodelle zu korrigieren und die Vorhersagen mehrerer Modelle zu kombinieren. Insbesondere Ensemlbe-Methoden wie Gradient Boosting haben sich als sehr leistungsfähig für strukturierte meteorologische Datensätze erwiesen [2] Präzise Windvorhersagen gewinnen durch den wachsenden Anteil von Windenergie immer weiter an Bedeutung. Eine zuverlässige Prognose ist für die Planung von Energieproduktion, die Stabilität von Stromnetzen sowie den Energiehandel entscheidend. Auch in der Luftfahrt, Landwirtschaft,

Bauwirtschaft sind präzise Vorhersagen von großer Wichtigkeit.Aber auch für Wassersportarten wie Kitesurfen sind präzise kurzfristige Windvorhersagen von großer Bedeutung.

Ziel dieser Arbeit ist die Entwicklung eines Machine Learning Modells zu Verbesserung kurzfristiger Windvorhersagen. Dabei werden die Vorhersagen mehrerer numerischer Wettermodelle und Messwerte lokaler Stationen als Eingabedaten verwendet. Das Modell sagt sowohl die mittlere Windgeschwindigkeit als auch die maximalen Windböen und die Windrichtung voraus. Die Vorhersage erfolgt multihorizontal für Zeiträume von einer bis zwölf Stunden.

2 Stand der Forschung

2.1 Machine Learning für Windvorhersagen

In den letzten Jahren hat Machine Learning zunehmend an Bedeutung für Meteorologische Vorhersageaufgaben gewonnen. Machine Learning Modelle können komplexe nichtlineare Zusammenhänge zwischen verschiedene meteorologischen Variablen erkennen und nutzen historische Daten, um zukünftige Werte vorherzusagen. Besonders bei tabellarischen Datensätzen haben sich Ensemblemethoden wie Random Forests oder Gradient Boosting als leistungsfähig erwiesen[5].

2.2 Unsicherheitsabschätzung

Neben der reinen Punktvorhersage gewinnt die Quantifizierung von Prognoseunsicherheiten zunehmend an Bedeutung. Meteorologische Vorhersagen sind grundsätzlich mit Unsicherheiten behaftet, die sowohl aus Modellfehlern als auch aus Unsicherheiten in den Eingangsdaten entstehen. Für viele praktische Anwendungen ist es daher entscheidend, nicht nur einzelne Vorhersagewerte, sondern auch Unsicherheiten zu diesen zu erhalten. In jüngerer Zeit hat sich das Verfahren der Conformal Prediction etabliert[7], das statistisch kalibrierte Vorhersageintervalle erzeugt. Diese Methode basiert auf der Analyse vergangener Vorhersagefehler und ermöglicht die Konstruktion von Intervallen, die mit einer vorgegebenen Wahrscheinlichkeit den tatsächlichen zukünftigen Wert enthalten, ohne starke Annahmen über die zugrunde liegenden Datenverteilung treffen zu müssen.

3 Datensatz

3.1 Datenquelle

Der in dieser Arbeit verwendete Datensatz basiert auf meteorologischen Beobachtungen von Messstationen in Holnis und Schausende. Diese Stationen liefern kontinuierliche Messungen von Windgeschwindigkeit, Windrichtung und maximale Windböen. Zusätzlich zu diesen Messwerten werden Historische Vorhersagen mehrerer numerischer Wettermodelle verwendet. Diese Modele liefern prognostizierte meteorologische Variablen für Zukünftige Zeitpunkte und bilden die Grundlage für die Eingangsvariablen des Machine learning Modells. Folgende numerischen Wettermodelle wurden verwendet:

- GFS 13km
- HARMONIE 5km
- ICON 2.2km
- ICON EU 7km
- IFS-HRES 9km
- MET NORDIC 1km

- WRFEUH 9km

Durch die Kombination dieser verschiedener regionalen und Globalen Modelle können unterschiedliche meteorologische Simulationen berücksichtigt werden. Der Datensatz umfasst mehrere Jahre Historischer Mess- und Vorhersagedaten. Die Daten wurden auf Anfrage von Windguru.cz zur Verfügung gestellt.

3.2 Eingangsvariablen

Die Eingangsvariablen des Modells bestehen aus Vorhersagen verschiedener meteorologischer Größen die von den numerischen Wettermodellen bereitgestellt werden. Berücksichtigt wurden hier:

- Windgeschwindigkeit in Knoten
- maximale Böen in Knoten
- Windrichtung in Grad
- Temperatur in Grad Celsius
- Relative Luftfeuchtigkeit in Prozent
- Luftdruck auf Meereshöhe in Hektopascal

3.3 Zielvariablen

Die Zielvariablen des Modells sind die drei Werte welche für die eigentliche Windvorhersage relevant sind:

- Windgeschwindigkeit in Knoten
- maximale Böen in Knoten
- Windrichtung in Grad

3.4 Datenaufbereitung

Die Datenaufbreitung erfolgte auf Basis mehrerer SQLite-Datenbanken, die sowohl Beobachtungen der Messstation als auch Vorhersagen verschiedener numerischer Wettermodelle enthalten. Zunächst wurden die Messdaten stündlich aggregiert, wobei die Windgeschwindigkeit als Mittelwert, die maximale Böe als Maximum und die Windrichtung als Mittelwert berechnet wurden. Anschließend wurden die Vorhersagedaten der einzelnen Wettermodelle geladen und für jeden Datensatz der Vorhersagehorizont in Stunden aus Initialisierungszeitpunkt und gültigem Vorhersagezeitpunkt berechnet. Hierbei wurde ein Vorhersagehorizont zwischen einer und zwölf Stunden berücksichtigt. Danach wurden die Vorhersagen aller Modelle zusammengeführt und die Beobachtungsdaten angehängt. Zudem wurden noch Wolken- und Niederschlagsdaten entfernt. Abschließend wurden alle Zeilen mit fehlenden Zielvariablen ausgeschlossen, sodass ein konsistenter Datensatz entsteht.

4 Methodik

4.1 Gradient Boosting

Gradient Boosting ist ein Ensembleverfahren des maschinellen Lernens, das mehrere Lernmodelle zu einem leistungsfähigen Gesamtmodell kombiniert.Typischerweise werden dabei Entscheidungsbäume als Basismodelle verwendet. Modelle werden dabei sequenziell trainiert, wobei jedes

neue Modell versucht, die Fehler der vorherigen Modelle zu korrigieren. Dieses verfahren basiert auf der Minimierung einer Verlustfunktion mithilfe von Gradientenabstieg im Funktionsraum [3]. Zu Beginn wir ein erstes Modell trainiert, welches eine grobe Vorhersage liefert. Anschließend wird der Fehler zwischen den vorhergesagten und tatsächlichen Werten berechnet. Ein weiteres Modell wird drauf trainiert diese Fehler zu approximieren. Durch die iterative Kombination mehrerer Modelle entsteht ein Ensemble, das zunehmend genauere Vorhersagen liefert.

4.2 XGBoost

Für die Modellierung der Vorhersage wurde wurde die Bibliothek XGBoost(Extreme Gradient Boosting)[2] verwendet. XGBoost ist eine optimierte Implementierung des Gradient boosting Verfahrens, die speziell auf Effizienz, Skalierbarkeit und hohe Vorhersagegenauigkeit ausgelegt ist. Das Verfahren nutzt Entscheidungsbäume als Basislerner und optimiert eine differenzierbare Verlustfunktion.

4.3 Multihorizontale Vorhersage

Die Windvorhersage wurde als Multihorizontales Prognoseproblem[6] formuliert. Dabei werden Vorhersagen für mehrere zukünftige Zeitschritte gleichzeitig erstellt. In diesem Projekt wurden Vorhersagehorizonte von einer bis zwölf Stunden betrachtet. Für jeden Vorhersagehorizont wurde ein separates Modell trainiert. Diese Strategie ermöglicht es dem Modell, die spezifischen statistischen Eigenschaft jedes Zeithorizonts zu berücksichtigen. Kurzfristige Vorhersagen basieren häufig stärker auf aktuellen Beobachtungen, während bei längeren Vorhersagehorizonten die Unsicherheit der Meteorologischen Modelle zunimmt. Durch die getrennte Modellierung kann das Lernverfahren diese Unterschiede explizit berücksichtigen.

4.4 Modellierung der Windrichtung

Die Windrichtung stellt eine zirkuläre Variable dar, da Werte von 0° und 360° dieselbe physikalische Windrichtung repräsentieren. Eine direkte Modellierung der Windrichtung als Winkel würde daher zu Problemen führen. Um dieses Problem zu vermeiden, wurde die Windrichtung mittels einer trigonometrischen Transformation in zwei Komponenten zerlegt. Der Winkel wurde in eine Sinus- und eine Cosinuskomponente transformiert. Das Modell sagt anschließend diese beiden Komponenten separat vorher. Aus den beiden Vorhersagen kann anschließend wieder der Winkel der Windrichtung berechnet werden. Diese Darstellung ermöglicht eine konsistente Modellierung zirkulärer Daten im rahmen eines Regressionsmodells.

4.5 Hyperparameter Optimierung

Für jedes Vorhersagemodell wurden zentrale Hyperparameter des XGBoost Algorithmus optimiert. Dazu gehört insbesondere die Anzahl der Entscheidungsbäume im Ensemble, die Lernrate sowie verscheidene Regularisierungsparameter. Die Optimierung erfolgte teilweise mittels eines Gitters aus möglichen Parameterwerten(Grid search). Für jeden Vorhersagehorizont wurden mehrere Kandidatenmodelle trainiert und anhand ihrer Validierungsfehler verglichen. Als Auswahlkriterium diente hauptsächlich der Root Mean Squared Error (RMSE). Der Parametersatz mit der besten durchschnittlichen Leistung auf den Validierungsdaten wurde anschließend für das finale Modell verwendet.

5 Conformal Prediction

Neben der Punktvorhersage wurde in dieser Arbeit zusätzlich eine Unsicherheitsabschätzung mithilfe von Conformal Prediction[7]durchgeführt. Dieser Ansatz ermöglicht es, für beliebige

Regressionsmodelle statistisch fundierte Vorhersageintervalle zu berechnen, ohne dass zusätzliche Annahmen über die Fehlerverteilung des Modells getroffen werden müssen. Die Grundidee besteht darin, die Fehlerverteilung des Modells auf einem separaten Kalibrierungsdatensatz zu analysieren. Aus den absoluten Residuen zwischen vorhergesagten und beobachteten Werten wird anschließend ein Quantil bestimmt, das zur Konstruktion symmetrischer Vorhersageintervalle um die Modellvorhersage verwendet wird. Für ein gewähltes Signifikanzniveau von $\alpha = 0.1$ ergibt sich dabei theoretisch eine erwartete Abdeckung von etwa 90 % der Beobachtungen.

Im Rahmen dieser Arbeit wurde Conformal Prediction auf Basis eines Kalibrierungszeitraums von 120 Tagen angewendet. Die absoluten Vorhersagefehler des trainierten XGBoost-Modells wurden genutzt, um entsprechende Quantile der Fehlerverteilung zu bestimmen und daraus Vorhersageintervalle für Windgeschwindigkeit und Windböen zu berechnen. Zusätzlich wurde eine regimebasierte Variante verwendet, bei der unterschiedliche Fehlerverteilungen für niedrige, mittlere und hohe Windgeschwindigkeiten berücksichtigt werden, um die unterschiedlichen Unsicherheiten bei verschiedenen Windbedingungen besser abzubilden.

6 Experimentelles Setup

6.1 Trainingsstrategie

Die Trainingsstrategie basiert auf einer zeit basierten Validierung, um die besonderen Eigenschaften meteorologischer Zeitreihendaten zu berücksichtigen. Im Gegensatz zu zufälligen Trainings- und Testaufteilungen wurde eine Walk-Forward-Validierungsstrategie 1 eingesetzt. Dabei wird das Modell iterativ auf historischen Daten trainiert und anschließend auf einer unmittelbar folgenden Zeitperiode validiert. Dabei werden mehrere Validierungs-Folds definiert, bei denen das Trainingsfenster schrittweise erweitert wird. Das Modell wird zunächst auf einem frühen historischen Zeitraum trainiert und auf den darauf folgenden Zeitraum angewendet. Anschließend wird das Trainingsfenster erweitert und der Prozess wiederholt. Diese Vorgehensweise ermöglicht eine realistische Bewertung der Modellleistung unter operationalen Bedingungen, da zu jedem Zeitpunkt nur Informationen aus der Vergangenheit für das Training genutzt werden.Zusätzlich wurde eine separater Holdout-Datensatz definiert, der zeitlich nach allen Trainings- und Validierungsdaten liegt und ausschließlich zur finalen Evaluation der Modelle verwendet wird.

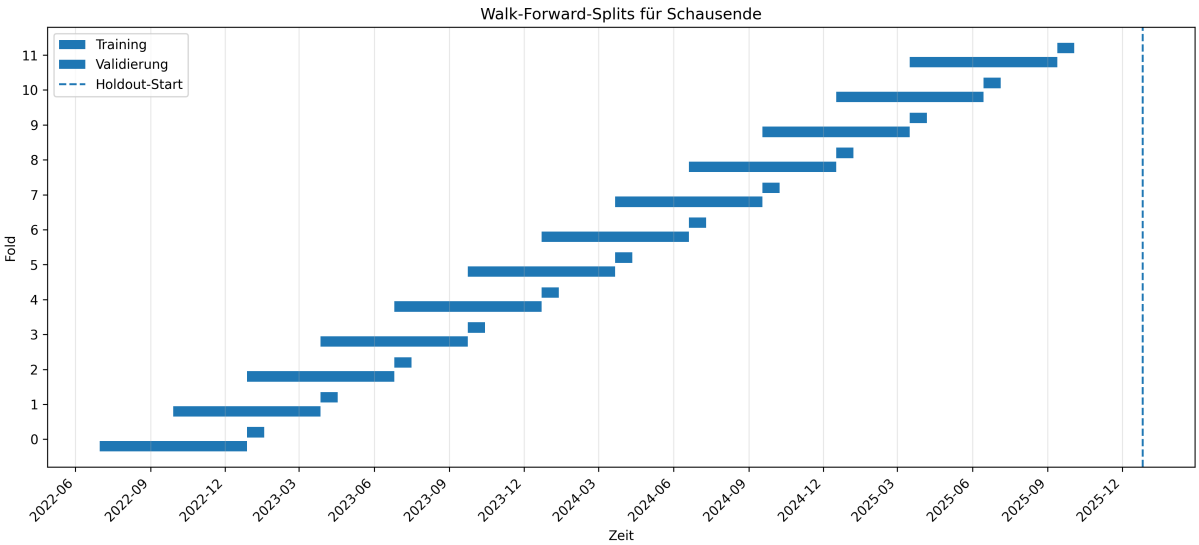

Abbildung 1: Zeitliche Aufteilung der Daten für die Walk Forward Validierung

6.2 Hyperparameter

Für das Training der Modelle wurden verschiedene Hyperparameter optimiert. Zu den wichtigsten Parametern gehörten die Anzahl der Bäume im Ensemble, die maximale Tiefer der Entscheidungsbäume, die Lernrate sowie Regularisierungsparameter. Diese Parameter beeinflussen maßgeblich die Modellkomplexität und damit die Fähigkeit des Modells aus den Daten zu lernen. Die Optimierung der Hyperparameter erfolgte teils mittels einer systematischen Suche über ein definiertes Parametergrid.(Für Jede Kombination von Parametern wurden Modelle trainiert und anhand ihrer Validierungsleistung verglichen. Als Auswahlkriterium diente primär der Root Mean Squared Error (RMSE) auf den Validierungsdaten. Durch diese Vorgehensweise wird sichergestellt, dass das finale Modell nicht nur auch den Traingsdaten gut funktioniert, sondern auch eine gute Generalisierungsfähigkeit auf unbekannten Daten aufweist.

Parameter	Wert
learning_rate	0.02
n_estimators grid	[200, 400, 600, 800, 1200, 1500, 3000]
max_depth	6
min_child_weight	6.0
gamma	0.5
subsample	0.8
colsample	0.8
reg_lambda	4.0
reg_alpha	0.0
max_folds	8
min_train	500
min_val	80
calibration_days	120
alpha	0.1
regime_conformal	True

Tabelle 1: Verwendete Hyperparameter und Trainingseinstellungen.

6.3 Evaluationsmetriken

Zur Bewertung der Modellleistung wurden mehrere etablierte Fehlermaße verwendet. Die zentrale Metrik ist der Root Mean Squared Error (RMSE), der die durchschnittliche quadratische Abweichung zwischen Vorhersage und Messwert misst. Der RMSE ist besonders sensitiv gegenüber großen Fehlern. Zusätzlich wurde der Mean Absolute Error (MAE) berechnet, der die durchschnittliche absolute Abweichung zwischen Vorhersage und Messwert beschreibt. Im Gegensatz zum RMSE gewichtet der MAE große Fehler weniger stark und liefert daher eine robuste Einschätzung über die durchschnittliche Modellgenauigkeit. Darüber hinaus wurde ein Bias bestimmt, der angibt, ob ein Modell systematisch zu hohe oder zu niedrige Werte vorhersagt. Für die Bewertung der Windrichtungsprognosen wurde ein Fehlermaß verwendet, das den zirkulären Charakter der Windrichtung berücksichtigt. Dabei wird die minimale Winkelabweichung zwischen vorhergesagter und beobachteter Richtung berechnet. Dieser Angular Mean Absolute Error (Angular MAE) ermöglicht ein konsistente Bewertung zirkulärer Variablen.

6.4 Hardware und Trainingsdauer

Trainiert wurde auf einem Apple MacBook Pro mit einem M4Max mit 64gb Unified Memory. XGBoost bietet keinen Apple Silicon GPU Support, weswegen auf der CPU trainiert werden musste. Ein Trainingslauf hat ca. 45min in Anspruch genommen.

7 Ergebnisse

Station	$\overline{\text{RMSE}}_{\text{speed}}$	Bereich	$\overline{\text{RMSE}}_{\text{gust}}$	Bereich	$\overline{\text{MAE}}_{\text{dir}}$	Bereich
Schausende	1.29 kn	1.13–1.38 kn	2.58 kn	2.44–2.79 kn	0.91°	0.85–1.01°
Holnis	2.32 kn	2.05–2.52 kn	4.04 kn	3.83–4.31 kn	0.75°	0.72–0.80°

Tabelle 2: Überblick über die wichtigsten Fehlermetriken über alle Vorhersagehorizonte.

Die vollständigen Fehlermetriken über alle Vorhersagehorizonte sind in Tabelle 3 für Schausende und in Tabelle 4 für Holnis dargestellt.

7.1 Windgeschwindigkeit

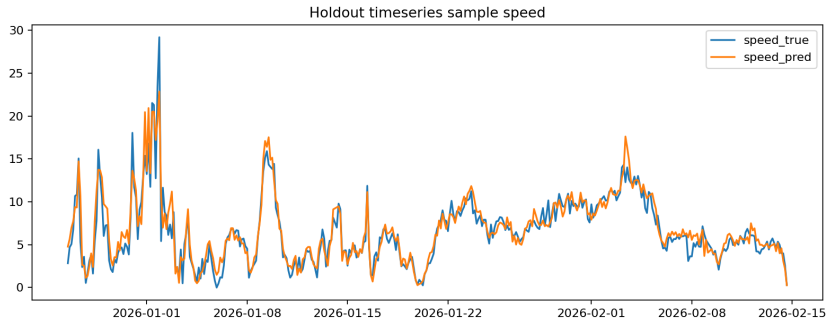

Abbildung 2: timeseries speed von Lead 03

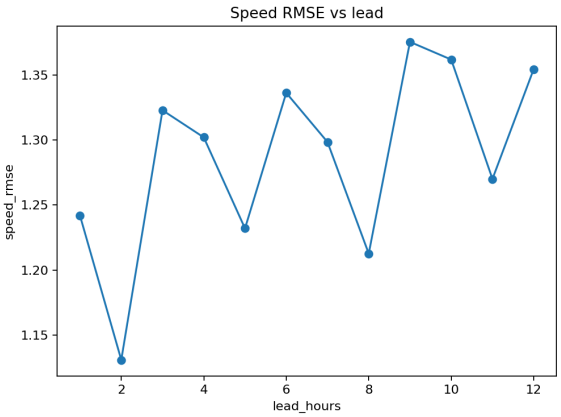

(a) RMSE Windgeschwindigkeit

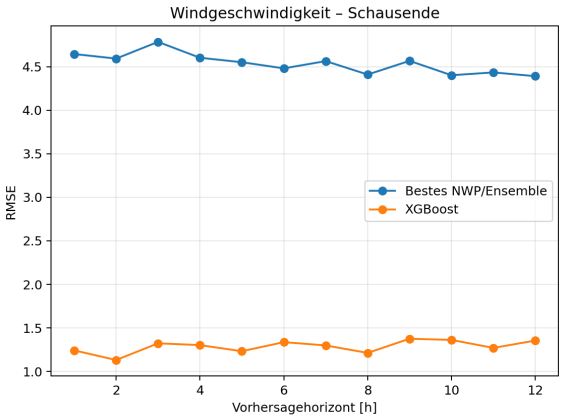

(b) RMSE Vergleich mit NWP

Abbildung 3: Fehler der Windgeschwindigkeit über verschiedene Lead Times und Vergleich mit NWP Modell

Die Ergebnisse zeigen eine konsistente Modellleistung über alle betrachteten Lead Times hinweg. Der RMSE der XGBoost Vorhersage liegt über alle Vorhersagehorizonte hinweg im Bereich von 1.13 bis 1.38 Knoten, mit einem durchschnittlichen Fehler von etwa 1.29 Knoten. Der geringste Fehler tritt bei einem Vorhersagehorizont von 2 Stunden (RMSE = 1.13 kn) auf, während der höchste Fehler bei 9 Stunden (RMSE = 1.38 kn) beobachtet wird. Auch der Mean Absolute Error liegt mit Werten zwischen 0.86 und 0.97 Knoten auf einem konstant niedrigen Niveau. Die entsprechenden R^2-Werte zwischen etwa 0.87 und 0.90 zeigen zudem, dass ein großer An-

teil der Varianz der Beobachteten Windgeschwindigkeit durch das Modell erklärt werden kann. Ein Vergleich mit den zugrunde liegenden numerischen Wettervorhersagemodellen zeigt eine deutliche Verbesserung durch das Machine learning Modell. Während die RMSE Werte der einzelnen NWP-Modelle im betrachteten Datensatz typischerweise zwischen etwa 4 bis 7 Knoten liegen, reduziert das trainierte Modell den Fehler auf etwa 1.3 Knoten. Dies entspricht einer durchschnittlichen Fehlerreduktion von rund 70 % gegenüber der Baseline Vorhersagen.

7.2 Windböen

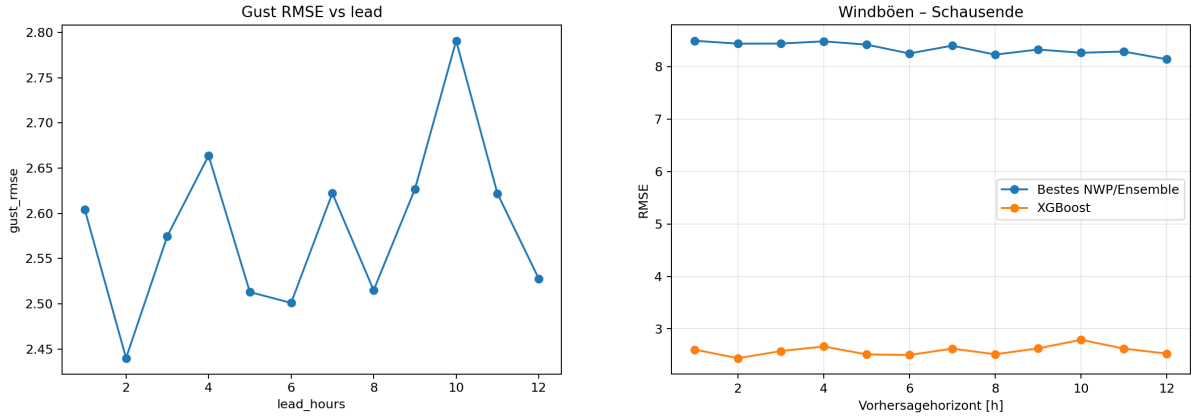

(a) RMSE Böen

(b) RMSE Vergleich mit NWP

Abbildung 4: Fehler der Windböen über verschiedene Lead Times und Vergleich mit NPW Modell

Die Ergebnisse zeigen eine stabile Modellleistung über alle betrachteten Vorhersagehorizonte hinweg. Der Root Mean Squared Error (RMSE) liegt zwischen 2.44 kn und 2.79 kn, mit einem durchschnittlichen Fehler von etwa 2.58 kn über alle Lead Times. Der niedrigste Fehler wird bei einem Vorhersagehorizont von 2 Stunden (RMSE = 2.44 kn) erreicht, während der höchste Fehler bei 10 Stunden (RMSE = 2.79 kn) auftritt. Trotz dieser Variation bleibt die Fehlergröße über den gesamten Vorhersagehorizont relativ konstant. Auch der Mean Absolute Error zeigt ein stabiles Verhalten und liegt über alle Lead Times hinweg im Bereich von etwa 1.88 kn bis 2.13 kn, mit einem durchschnittlichen Wert von rund 1.99 kn. Die Bestimmtheitsmaße liegen zwischen $R^2 = 0.74$ und $R^2 = 0.80$, was darauf hinweist, dass ein großer Teil der Variabilität der beobachteten Böen durch das Modell erklärt werden kann. Ein Vergleich mit den zugrunde liegenden numerischen Wettervorhersagemodellen zeigt eine deutliche Verbesserung durch das Machine Learning Modell. Während die RMSE Werte der einzelnen NWP Modelle im betrachteten Datensatz typischerweise im Bereich von etwa 8–12 kn liegen, reduziert das trainierte XGBoost Modell den Fehler auf etwa 2.6 kn. Dies entspricht einer durchschnittlichen Fehlerreduktion von ungefähr 65–75 % gegenüber den besten verfügbaren Baseline Vorhersagen. Die Ergebnisse zeigen damit, dass das Machine Learning Modell in der Lage ist, systematische Fehler der numerischen Modelle zu korrigieren und die kurzfristige Vorhersage von Windböen deutlich zu verbessern.

7.3 Windrichtung

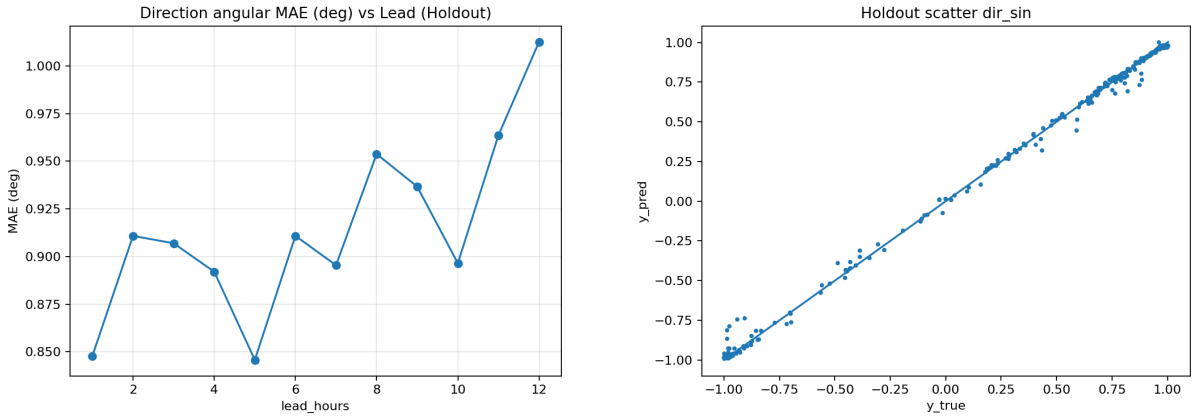

(a) MAE der Windrichtung

(b) lead 03 Sinus Komponente der Direction

Abbildung 5: Fehler der Windrichtung über verschiedene Lead Times und Scatter der sin Komponente

Der mittlere Winkelfehler liegt im Bereich von etwa 0.85° bis 1.01°, mit einem durchschnittlichen Fehler von rund 0.91° über alle Lead Times. Der geringste Fehler tritt bei einem Vorhersagehorizont von 5 Stunden mit etwa 0.85° auf, während der höchste Fehler bei einem Vorhersagehorizont von 12 Stunden etwa 1.01° beträgt. Trotz dieser leichten Variation bleibt die Modellleistung über den gesamten Vorhersagehorizont von zwölf Stunden sehr stabil. Die Ergebnisse zeigen damit, dass das Modell die zugrunde liegenden Strömungsmuster zuverlässig erfasst und eine sehr präzise Rekonstruktion der Windrichtung ermöglicht. Durch die Verwendung der Sinus- und Kosinusdarstellung kann das Modell die zyklische Struktur der Richtungsdaten korrekt berücksichtigen.

7.4 Unsicherheitsabschätzung

Die Ergebnisse zeigen, dass die erzeugten Vorhersageintervalle zusätzliche Informationen über die Unsicherheit der Modellprognosen liefern. Allerdings liegt die beobachtete Coverage der Intervalle teilweise unter dem theoretisch erwarteten Wert von 90 %. Dies deutet darauf hin, dass sich die Fehlerverteilung zwischen Trainings-, Kalibrierungs- und Testzeitraum verändert haben kann, was bei meteorologischen Zeitreihen aufgrund ihrer zeitlichen Nichtstationarität häufig auftritt. Trotz dieser Einschränkung ermöglicht der Ansatz eine sinnvolle Quantifizierung der Prognoseunsicherheit und ergänzt die Punktvorhersagen des Machine-Learning-Modells um eine probabilistische Komponente.

8 Diskussion

Der Ansatz weist auch einige Limitationen auf. So zeigt sich beispielsweise, dass die Modellleistung zwischen den untersuchten Stationen variiert, was auf lokale meteorologische Effekte und unterschiedliche Standortbedingungen zurückzuführen sein kann. Darüber hinaus basiert das Modell ausschließlich auf historischen Daten und numerischen Vorhersagen, wodurch unvorhergesehene meteorologische Ereignisse nur eingeschränkt erfasst werden können. Auch die Unsicherheitsabschätzung mittels Conformal Prediction zeigte eine teilweise geringere Coverage als theoretisch erwartet, was darauf hinweist, dass sich die Fehlerverteilungen zwischen Trainings- und Testzeitraum verändern können. Diese Aspekte sollten in zukünftigen Arbeiten weiter untersucht werden. Zudem muss berücksichtigt werden, dass lediglich die Vorhersage der Messwerte

verbessert wurde. Der tatsächlich vorherrschende Wind kann je nach lokaler Gegebenheit stark davon abweichen. So können Beispielsweise Windabdeckungen bei bestimmtem Windrichtungen durch Gebäude, Vegetation oder Ähnliches die Messwerte stark verfälschen. Das Modell würde diese Fehler dann lernen.

9 Fazit

In dieser Arbeit wurde ein Machine-Learning-basierter Ansatz zur kurzfristigen Vorhersage von Windgeschwindigkeit, Windböen und Windrichtung untersucht. Hierfür wurde ein Gradient-Boosting-Modell (XGBoost) trainiert, das auf numerischen Wettervorhersagen mehrerer Modelle sowie auf historischen Messdaten basiert. Ziel der Arbeit war es, zu untersuchen, inwieweit Machine Learning Methoden in der Lage sind, systematische Fehler numerischer Wettervorhersagemodelle zu korrigieren und dadurch die Vorhersagequalität zu verbessern.

Die Ergebnisse zeigen, dass das entwickelte Modell über alle betrachteten Vorhersagehorizonte hinweg eine stabile und hohe Vorhersagegenauigkeit erreicht. Für die mittlere Windgeschwindigkeit konnte ein RMSE im Bereich von etwa 1.13 bis 1.38 kn in Schausende beziehungsweise 2.05 bis 2.52 kn in Holnis erzielt werden. Auch für die Vorhersage von Windböen zeigte das Modell robuste Ergebnisse mit RMSE-Werten von etwa 2.4 bis 2.8 kn. Die Windrichtung konnte mit einem mittleren Winkelfehler von etwa 0.9° sehr präzise rekonstruiert werden. Insgesamt erklären die Modelle einen großen Anteil der beobachteten Varianz, was sich in R^2-Werten von etwa 0.87 bis 0.93 widerspiegelt. Ein Vergleich mit den zugrunde liegenden numerischen Wettervorhersagemodellen zeigt eine deutliche Verbesserung durch den Machine-Learning-Ansatz. Während die RMSE-Werte der einzelnen NWP-Modelle typischerweise zwischen etwa 4 und 7 kn liegen, reduziert das trainierte Modell den Fehler auf etwa 1–2 kn. Damit zeigt sich, dass das Modell in der Lage ist, systematische Fehler der numerischen Vorhersagen effektiv zu korrigieren.

Zusätzlich wurde eine Unsicherheitsabschätzung mittels Conformal Prediction durchgeführt, um neben Punktvorhersagen auch Vorhersageintervalle zu erzeugen. Die Ergebnisse zeigen, dass diese Intervalle wertvolle Informationen über die Prognoseunsicherheit liefern können, auch wenn die beobachtete Coverage teilweise unter dem theoretisch erwarteten Wert liegt.

Insgesamt verdeutlichen die Ergebnisse das Potenzial von Machine-Learning-Methoden zur Verbesserung kurzfristiger Windvorhersagen. Durch die Kombination numerischer Wettermodelle mit datengetriebenen Korrekturverfahren können signifikante Genauigkeitsgewinne erzielt werden. Zukünftige Arbeiten könnten untersuchen, inwieweit zusätzliche meteorologische Variablen, längere Trainingszeiträume oder alternative Modellarchitekturen die Vorhersagequalität weiter verbessern können.

Abbildungsverzeichnis

1 Zeitliche Aufteilung der Daten für die Walk Forward Validierung 5
2 timeseries speed von Lead 03 7
3 Fehler der Windgeschwindigkeit über verschiedene Lead Times und Vergleich mit NWP Modell 7
4 Fehler der Windböen über verschiedene Lead Times und Vergleich mit NPW Modell 8
5 Fehler der Windrichtung über verschiedene Lead Times und Scatter der sin Komponente 9

A Vollständige Ergebnisübersichten

$\text{lead}_h ours$	$\text{speed}_r mse$	$\text{speed}_m ae$	$\text{speed}_b ias$	$\text{speed}_r 2$	$\text{gust}_r mse$	$\text{gust}_m ae$	$\text{gust}_b ias$	$\text{gust}_r 2$	$\text{dir}_a ngular_m ae_d eg$
1	1.24	0.9	0.39	0.89	2.6	2.08	1.82	0.78	0.85
2	1.13	0.86	0.18	0.91	2.44	1.96	1.52	0.8	0.91
3	1.32	0.93	0.26	0.88	2.57	1.98	1.65	0.78	0.91
4	1.3	0.91	0.43	0.88	2.66	2.1	1.81	0.77	0.89
5	1.23	0.92	0.3	0.89	2.51	1.93	1.56	0.79	0.85
6	1.34	0.9	0.19	0.88	2.5	1.9	1.55	0.8	0.91
7	1.3	0.92	0.32	0.88	2.62	2.05	1.72	0.77	0.9
8	1.21	0.92	0.3	0.9	2.52	2.0	1.65	0.79	0.95
9	1.38	0.97	0.24	0.87	2.63	1.94	1.48	0.77	0.94
10	1.36	0.94	0.3	0.87	2.79	2.13	1.83	0.74	0.9
11	1.27	0.94	0.13	0.89	2.62	1.99	1.55	0.77	0.96
12	1.35	0.95	0.15	0.88	2.53	1.88	1.42	0.79	1.01

Tabelle 3: Vollständige Ergebnisübersicht über alle Vorhersagehorizonte für die Station Schausende.

$\text{lead}_h ours$	$\text{speed}_r mse$	$\text{speed}_m ae$	$\text{speed}_b ias$	$\text{speed}_r 2$	$\text{gust}_r mse$	$\text{gust}_m ae$	$\text{gust}_b ias$	$\text{gust}_r 2$	$\text{dir}_a ngular_m ae_d eg$
1	2.41	1.84	1.18	0.9	4.09	3.24	2.95	0.8	0.74
2	2.05	1.61	1.03	0.93	4.2	3.35	3.01	0.78	0.75
3	2.34	1.79	1.22	0.9	4.08	3.26	2.91	0.8	0.75
4	2.52	1.92	1.33	0.89	4.25	3.38	3.08	0.78	0.72
5	2.25	1.7	1.06	0.91	3.98	3.18	2.84	0.81	0.75
6	2.47	1.85	1.16	0.89	3.98	3.14	2.77	0.81	0.76
7	2.51	1.85	1.07	0.89	3.92	3.12	2.72	0.81	0.72
8	2.23	1.73	0.99	0.91	4.11	3.33	2.91	0.79	0.77
9	2.4	1.82	1.11	0.9	3.98	3.17	2.71	0.81	0.75
10	2.31	1.77	1.04	0.9	3.83	3.06	2.62	0.82	0.75
11	2.19	1.66	0.82	0.91	3.83	3.06	2.65	0.82	0.73
12	2.49	1.84	1.06	0.89	4.13	3.24	2.81	0.79	0.79

Tabelle 4: Vollständige Ergebnisübersicht über alle Vorhersagehorizonte für die Station SHolnis.

Literatur

[1] Peter Bauer, Alan Thorpe, and Gilbert Brunet. The quiet revolution of numerical weather prediction. *Nature*, 2015.

[2] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *KDD*, 2016.

[3] Jerome H. Friedman. Greedy function approximation: A gradient boosting machine. *Annals of Statistics*, 2001.

[4] David Gagne. Machine learning for postprocessing ensemble weather forecasts. *Monthly Weather Review*, 2014.

[5] Y. Ren. Wind power prediction: A review. *Renewable Energy*, 2019.

[6] Souhaib Ben Taieb and Rob Hyndman. A review and comparison of strategies for multi-step ahead time series forecasting. *International Journal of Forecasting*, 2014.

[7] Vladimir Vovk, Alexander Gammerman, and Glenn Shafer. Inductive conformal prediction for regression. *arXiv preprint arXiv:0706.3188*, 2007.

[8] Yong Zhang and Jianzhou Wang. A review of wind speed forecasting models. *Renewable and Sustainable Energy Reviews*, 2014.